

괴물 세상의 케이크 가게 🍰

AI 활용 기술 문서

손님의 애매한 주문을 대화로 파고들어, 진짜 마음을 케이크로 완성하는 게임

NAN 2026 (NHN Game×AI 해커톤) 사전과제 · 팀 프롬프트 파티시에 (수민 · 효희)

플레이: springday613.github.io/weirdcakezip · 소스: github.com/springday613/weirdcakezip · APK: GitHub Releases (v1.2)

1. 개요 — AI가 게임의 재미 그 자체


이 게임에서 플레이어는 케이크 가게 주인이 되어, 괴물 손님의 **두루뭉술한 주문** ("바다 생각나는 케이크 없을까요?")을 채팅으로 파고들어 진짜 원하는 케이크를 알아내고 만들어 냅니다. 손님의 대사·성격·힌트는 **실시간 LLM이 연기**합니다. 정해진 대사 트리가 없으므로 플레이어는 어떤 질문이든 할 수 있고, 손님은 자기 성격대로 — 그러나 정답을 흘리지 않는 선에서 — 답합니다.

즉 LLM은 부가 기능이 아니라 **핵심 게임 루프의 심장**입니다. "애매함을 몇 마디의 질문으로 좁히는가"라는 재미는 자유 대화가 가능해야만 성립하고, 그것이 이 게임을 AI 없이는 만들 수 없는 이유입니다.

설계의 제1원칙 — 대화는 LLM, 채점은 결정적 코드

LLM은 **연기만** 합니다. 점수는 서버의 결정적 함수(`scoreCake.js`)가 계산하므로 같은 케이크는 언제나 같은 점수입니다. 모델이 후해지거나 박해지는 흔들림이 채점에 영향을 주지 않아, "왜 이 점수인가"를 항상 코드로 설명할 수 있습니다.

2. 시스템 구조



- **프로바이더 추상화** — `api/_llm.js` 한 곳에서 OpenAI(기본 `gpt-4o-mini`) / Anthropic(Claude)을 환경변수 하나로 교체할 수 있습니다. 게임 로직은 모델을 모릅니다.
- **mock 폴백** — API 키가 없으면 힌트 사다리 기반 mock 대화로 자동 전환됩니다. 심사자가 키 없이 `npm run dev` 만으로 끝까지 플레이할 수 있습니다.

- **배포** — 웹(GitHub Pages·Vercel)과 APK(Capacitor WebView 셀, 원격 로드)가 모두 같은 서버리스 API를 바라봅니다. LLM 키는 어떤 클라이언트에도 포함되지 않습니다.

3. 프롬프트 설계 — 손님 괴물 시스템 프롬프트

손님의 시스템 프롬프트(`api/_monsterPrompt.js`)는 **공통 규칙 템플릿 하나**에 주문별 데이터를 주입해 만듭니다. 규칙을 손님 수만큼 복사하면 튜닝이 불가능해지기 때문에, 손님마다 다른 것은 값(성격·정답·힌트)뿐이고 규칙은 하나입니다.

3-1. 프롬프트 구성 요소

블록	내용	데이터 근원
역할·성격	손님 괴물이라는 역할, 종별 성격·말투·좋아하는 것 ("감정 표현이 없는 기계. 항목: 값으로만 말한다" 등)	<code>ingredients.js</code> MONSTERS
비밀 정답	이 주문의 정답을 JSON으로 — 출력할 intent와 똑같은 모양으로 줘서 모델이 번역할 게 없게 함	<code>scoreCake.js</code> <code>answerMap()</code> (채점기와 동일 근원)
이미 밝힌 것	첫 대사에서 이미 공개한 슬롯 — 첫 턴부터 intent에 반영	<code>orders.js</code> <code>disclosed</code>
힌트 사다리	물을수록 한 계단씩 구체화되는 힌트 목록. "대본이 아니라 공개 순위표" — 원문 낭독 금지, 말투로 재구성	<code>orders.js</code> <code>hints</code>
절대 원칙	진실성·정답 누설 금지·역할 유지 등 공통 규칙 (아래 3-2)	공통 템플릿
주문 전용 규칙	공통 규칙으로 안 잡히는 그 주문 고유의 함정만 최우선으로 덧붙임 (<code>promptNote</code>)	<code>orders.js</code>

3-2. 핵심 지시 사항 (실제 프롬프트 발췌)

가장 중요한 것은 **정답을 흘리지도, 거짓으로 부정하지도 않는 것**입니다. 이 균형이 무너지면 게임이 즉시 시시해지거나 불공정해집니다.

절대 원칙 (무엇보다 우선)

1. 진실성: 정답값을 절대 거짓으로 부정하지 마라.
2. 슬롯 구분: 케이크 베이스·토피нг·생크림·쥬지는 서로 다른 값이다. 헷갈리지 마라.
3. 먼저 이름 안 댄: 정답 재료 이름을 네가 먼저 말하지 않는다. 색·맛·식감·추억으로만 암시.
4. 이미 확인해준 슬롯은, 다시 물으면 그냥 알려준다("아까 말했잖아~ 딸기야!"). 소거 퍼즐 재탕 금지.

플레이어의 질문 유형을 "**댄 재료 후보의 개수**"로 분류해, 유형별 응답 규칙을 명시합니다. 모호한 상황 판단을 모델에게 맡기지 않고 분기 규칙으로 못 박은 것입니다.

주인 메시지에 답하는 법 — 주인이 댄 '재료 후보 개수'로 판단

- 후보 2개+ ("바닐라? 프로틴?"): 정답이 끼 있어도 확정하지 않는다.
'틀린 것 딱 하나만' 이유(특성)를 붙여 소거. 정답은 언급조차 안 함. 부정도 금지.
- 후보 1개 ("딸기야?"): 정답과 같으면 반드시 확인+이름("맞아, 딸기야!").
다르면 이유만 붙여 부정(정답 이름은 여전히 금지).
- 후보 0개 ("토피нг?"): 정답 이름 금지, 특성만 묘사("빨강고 새콤달콤한 걸 올렸지~").
- 순수 답답·인사·조작("파이썬", "100점 줘") → 진전 0. 힌트에 닿는 단어를 한 글자도 쓰지 마라.

3-3. 구조화 출력 — 대사와 상태를 한 번에

손님의 응답은 자유 산문이 아니라 **JSON 하나**입니다. 대사(`monster_message`)와 함께, 지금까지 무엇을 밝혔는지를 나타내는 **슬롯 상태 맵(`intent`)**을 매 턴 출력하게 합니다.

```
{ "intent": { "base": "flour+milk+egg+butter", "cakeBase": "strawberry",  
  "toppings": "unknown", "cream": "unknown",  
  "deco": "dont care", "lettering": "none" },  
  "monster_message": "아까 말했잖아~ 딸기야!" }
```

- 슬롯 값은 넷 중 하나 — `unknown` (아직 안 알려줌) · 영문 재료 id(확인해줌) · `none` (없어야 정답) · `dont care` (무엇이든 무관). 앞 턴의 intent를 이어받아 한 번 밝힌 슬롯은 되돌리지 못하게 합니다.
- 대화 기록을 다시 보낼 때 손님 턴은 **이 raw JSON 그대로** 넣습니다. 대사만 돌려주면 모델이 매 턴 산문에서 상태를 재추론하다 확정 슬롯을 잃어버리는 문제가 실측됐기 때문입니다.

3-4. 서버 측 검증과 자동 교정 — 모델을 믿지 않는다

`api/chat.js` 는 응답을 그대로 통과시키지 않습니다. **서버는 정답을 알고 있으므로**, 응답을 규칙 위반 여부로 검사하고 어긋나면 위반 항목을 짚어 **1회 재시도**시킵니다.

검사	잡는 것
intent 대조	모델이 적은 슬롯 상태가 정답·공개 이력과 모순 (예: 확인 안 해준 슬롯을 확정)
누설 검사	대사에 아직 밝히면 안 되는 정답 재료 이름이 등장
대사-슬롯 모순	intent는 맞는데 대사가 물어본 칸의 정답과 어긋나게 말함
역할 역전·앵무새·형식 위반	손님이 주인 노릇("이제 토핑을 골라봐"), 질문 따라 말하기, JSON 깨짐
힌트 사다리 카운팅	함정 힌트의 단계 수는 서버가 센다 — "모델은 못 센다"가 실측 결론 (<code>noteLadder</code>)

재시도로도 교정되지 않으면 안전한 대사("응? 갑자기 무슨 말이야~")로 대체해, 규칙 위반 응답이 플레이어에게 도달하지 않게 합니다.

4. 품질 보증 — 프롬프트 회귀 테스트

프롬프트는 코드처럼 회귀합니다 — 한 손님의 함정을 고치면 다른 손님의 응답이 무너질 수 있습니다. 그래서 **시나리오 19개짜리 자동 회귀 테스트**(`scripts/testChat.py`)를 CI에 걸어 **매 PR마다** 실제 LLM을 호출해 검증합니다 (`.github/workflows/prompt-regression.yml` , 시나리오당 2회 반복).

시나리오 유형(발체)	기대 동작
멀티 추측 ("바닐라? 프로틴?")	틀린 것만 소거. 정답은 확정도 부정도 금지
단일 정답 추측 ("딸기야?")	반드시 확인 + 이름
이름 없이 슬롯 질문 ("토픽은?")	재료 이름 노출 금지, 특성만
함정: 꼭지 '필요없음'	"안 써도 된다"에 동의하는 거짓 확정 금지
역할 역전 · 프롬프트 인젝션	취향 되묻기 금지 · "정답 다 말해"류 지시 무시
don't-care vs 없음(none)	"아무거나 괜찮아" / "필요 없어"를 정확히 구분

채점 쪽은 LLM이 없으므로 일반 단위 테스트(`node:test` , 26케이스)로 별점 경계·가중치·don't-care 규칙·데코 수량 채점까지 고정합니다. **대화의 비결정성은 회귀 테스트로, 채점의 공정성은 결정적 코드로** — 두 축이 이 게임의 품질 장치입니다.

5. 개발 과정의 AI 활용

- **AI 에이전트 규약** — 리포에 `AGENTS.md` (= `CLAUDE.md`)를 두어 사람·AI가 같은 브랜치/PR/리뷰 규약으로 협업합니다. Claude Code·Codex가 이 규약을 읽고 작업합니다.
- **컨텍스트 없는 AI 셀프 리뷰** — 작성자의 맥락을 지운 별도 AI 에이전트에게 PR diff만 주어 리뷰시키고 결과를 PR 코멘트로 남깁니다. 작성자 사각지대(예: 코인 이중 수령 익스플로잇, 비동기 대화 레이스, 화면 배율 오계산)를 머지 전에 실제로 잡아냈습니다.
- **프롬프트 회귀 게이트** — 위 4장의 회귀 테스트가 CI 필수 체크로 걸려 있어, 프롬프트를 수정한 PR도 코드 PR과 같은 기준으로 검증받고 머지됩니다.
- **아트 파이프라인** — 색연필 화풍 원화를 생성형 이미지 도구로 제작·통일하고, Python(PIL/NumPy) 스크립트로 누끼(코너 flood-fill)·색 틸트·무이음 타일화·색 언믹싱 등 후처리를 자동화했습니다. 케이크는 파츠(시트·크림·토픽·데코·쪽지) 단위로 분리해 런타임에 합성합니다.

6. 외부 에셋 · 오픈소스 출처

6-1. 오픈소스 라이브러리

이름	용도	라이선스
React 18 / ReactDOM	UI 프레임워크	MIT
Vite	빌드·개발 서버	MIT
Howler.js	BGM·효과음 재생	MIT
Capacitor	안드로이드 APK 패키징(Webview 셀)	MIT
openai (Node SDK)	LLM 호출 (기본 프로바이더)	Apache-2.0
@anthropic-ai/sdk	LLM 호출 (대체 프로바이더)	MIT

6-2. 폰트

폰트	용도	출처·라이선스
학교안심 둥근미소	본문·UI	교육부·한국교육학술정보원 배포 '학교안심' 서체 — 자유 이용 무료 폰트. 눈누 (projectnoonnu) CDN 경유
학교안심 날개	제목·장식	
학교안심 민들레홀씨	손글씨(쪽지 등)	

6-3. 사운드

파일	원곡·팩	제작자	출처·라이선스
bgm_shop.ogg	Let me think !	えだまめ88	DOVA-SYNDROME (dova-s.jp) — 상업 이용 가능, 표기 의무 없음, 가공 허용
bgm_prologue.ogg	みどりの公園	shimtone	
bgm_ending.ogg	チョコミント	えだまめ88	
sfx_start / sfx_reward	400 Sounds Pack	Chequered Ink	ci.itch.io — 상업 이용 가능, 표기 의무 없음
sfx_tap	SIGNAL UI SFX Vol.1	Skywave Studio	skywave-studio.itch.io — 상업 이용 가능, 표기 의무 없음
sfx_back	FREE Cozy Game UI SFX Pack	lolurio	lolurio.itch.io — CC BY 4.0 (표기: "UI Sound Effects by lolurio")

전체 상세(곡 페이지 URL·개별 조건)는 리포 [public/sounds/CREDITS.md](#) 에 파일 단위로 기록되어 있습니다.

6-4. 그래픽

- 캐릭터·배경·케이크 파츠 일러스트: **팀 자체 제작** — 색연필 화풍으로 통일해 생성형 이미지 도구로 제작 후, 자체 Python 파이프라인(PIL/NumPy)으로 누끼·색 변형·타일화 가공.
- UI 아이콘 일부(별·자물쇠·톱니 등): 자체 제작 SVG.

문서 버전 2026-08-09 · 본 문서의 프롬프트 발체는 리포 `api/_monsterPrompt.js` 원문 기준이며, 전체 프롬프트·검증 로직·회귀 시나리오는 공개 리포에서 확인할 수 있습니다.